

Statistica

Leonardo Ganzaroli

Indice

1	Elementi utili	2
2	Campioni e statistiche	6
3	Stimatori	9
3.1	MLE	9
3.2	Metodo dei momenti	10
3.3	Bayes	11
3.4	Proprietà e teoremi vari	12
4	Test d'ipotesi e intervalli di confidenza	14
4.1	IC	14
4.2	Test	16
5	Test χ^2	20
5.1	Bontà di adattamento	20
5.2	Indipendenza	21
6	ANOVA a una via	22
7	Algoritmo EM	23

1 Elementi utili

Bernoulli

$$X \sim \text{Ber}(p)$$

$$P(X = x) = p^x(1-p)^{1-x}, \quad x \in \{0, 1\},$$

$$E[X] = p, \quad \text{Var}(X) = p(1-p).$$

Binomiale

$$X \sim \text{Bin}(n, p)$$

$$P(X = x) = \binom{n}{x} p^x (1-p)^{n-x}, \quad x = 0, \dots, n,$$

$$E[X] = np, \quad \text{Var}(X) = np(1-p).$$

Multinomiale

$$(X_1, \dots, X_k) \sim \text{Mult}(n, p_1, \dots, p_k)$$

$$P(X_1 = x_1, \dots, X_k = x_k) = \frac{n!}{x_1! \dots x_k!} \prod_{i=1}^k p_i^{x_i}, \quad \sum_{i=1}^k x_i = n,$$

$$E[X_i] = np_i, \quad \text{Var}(X_i) = np_i(1-p_i).$$

Poisson

$$X \sim \text{Pois}(\lambda)$$

$$P(X = x) = \frac{\lambda^x e^{-\lambda}}{x!}, \quad x = 0, 1, 2, \dots, \lambda > 0$$

$$E[X] = \text{Var}(X) = \lambda.$$

Uniforme continua

$$X \sim U(a, b)$$

$$f(x) = \frac{1}{b-a}, \quad a < x < b,$$

$$E[X] = \frac{a+b}{2}, \quad \text{Var}(X) = \frac{(b-a)^2}{12}.$$

Esponenziale

$$X \sim \text{Exp}(\lambda)$$

$$f(x) = \lambda e^{-\lambda x}, \quad x, \lambda > 0,$$

$$E[X] = \frac{1}{\lambda}, \quad \text{Var}(X) = \frac{1}{\lambda^2}.$$

Gamma (β parametro di tasso)

$$X \sim \Gamma(\alpha, \beta)$$

$$f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, \quad x > 0, \alpha, \beta > 0,$$

$$E[X] = \frac{\alpha}{\beta}, \quad \text{Var}(X) = \frac{\alpha}{\beta^2}.$$

Si ha

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exp}(\lambda) \Rightarrow \sum_{i=1}^n X_i \sim \Gamma(n, \lambda)$$

Inoltre

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim \Gamma(n, n\lambda)$$

Beta

$$X \sim \text{Beta}(\alpha, \beta)$$

$$f(x) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1}, \quad 0 < x < 1, \alpha, \beta > 0,$$

$$E[X] = \frac{\alpha}{\alpha + \beta}, \quad \text{Var}(X) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}.$$

Normale

$$X \sim N(\mu, \sigma^2)$$

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad \sigma > 0,$$

$$E[X] = \mu, \quad \text{Var}(X) = \sigma^2.$$

$$\text{N.B.} \quad X \sim N(\mu, \sigma^2) \Rightarrow Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

Se

$$X_1, \dots, X_n \text{ indipendenti}, \quad X_i \sim N(\mu_i, \sigma_i^2)$$

allora

$$\sum_{i=1}^n X_i \sim N\left(\sum_{i=1}^n \mu_i, \sum_{i=1}^n \sigma_i^2\right)$$

Inoltre

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2) \Rightarrow \bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

t di Student

$$\boxed{X \sim t_\nu}$$

$$f(x) = \frac{\Gamma(\frac{\nu+1}{2})}{\sqrt{\nu\pi}\Gamma(\frac{\nu}{2})} \left(1 + \frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}},$$

$$E[X] = 0 \quad (\nu > 1), \quad \text{Var}(X) = \frac{\nu}{\nu-2} \quad (\nu > 2).$$

Se

$$Z \sim N(0, 1), \quad V \sim \chi_\nu^2$$

sono indipendenti, allora

$$\frac{Z}{\sqrt{V/\nu}} \sim t_\nu$$

Inoltre:

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2) \Rightarrow \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}$$

Chi-quadro

$$\boxed{X \sim \chi_k^2}$$

$$Z_1, \dots, Z_k \stackrel{\text{iid}}{\sim} N(0, 1) \Rightarrow \sum_{i=1}^k Z_i^2 \sim \chi_k^2,$$

$$E[X] = k, \quad \text{Var}(X) = 2k.$$

Si ha

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2) \Rightarrow \boxed{\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2}$$

Nota: S^2 è la varianza campionaria, vedere la sezione 2.

F di Fisher

$$X \sim F_{d_1, d_2}$$

Se

$$A \sim \chi_{d_1}^2, \quad B \sim \chi_{d_2}^2$$

sono indipendenti, allora

$$X = \frac{A/d_1}{B/d_2} \sim F_{d_1, d_2}$$

$$E[X] = \frac{d_2}{d_2 - 2}, \quad d_2 > 2, \quad \text{Var}(X) = \frac{2d_2^2(d_1 + d_2 - 2)}{d_1(d_2 - 2)^2(d_2 - 4)}, \quad d_2 > 4.$$

Legge (debole) dei Grandi Numeri:

Se

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} X$$

con

$$E[|X|] < \infty, \quad E[X] = \mu$$

allora

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \mu$$

Teorema del Limite Centrale:

Se

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} X$$

con

$$E[X] = \mu, \quad \text{Var}(X) = \sigma^2 < \infty$$

allora:

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} N(0, 1)$$

ovvero con n grande:

$$\bar{X} \approx N\left(\mu, \frac{\sigma^2}{n}\right)$$

2 Campioni e statistiche

Definizione Un campione casuale di taglia n è una sequenza di variabili aleatorie iid con distribuzione F_θ e θ parametro ignoto:

$$X_1, X_2, \dots, X_n \stackrel{\text{iid}}{\sim} F_\theta$$

Alcuni metodi per generare campioni casuali:

- **Metodo dell'inversione**

Data la funzione di ripartizione $F(x) = P(X \leq x)$;

Si genera un numero casuale u da $U(0, 1)$;

Si calcola $x = F^{-1}(u)$;

Il numero x sarà distribuito secondo F .

- **Trasformazione di Box-Muller (originale)**

Prendo $U_1, U_2 \sim U(0, 1)$;

Con le seguenti formule si ottengono due gaussiane standard indipendenti:

$$Z_1 = \sqrt{-2 \ln(U_1)} \cos(2\pi U_2), \quad Z_2 = \sqrt{-2 \ln(U_1)} \sin(2\pi U_2)$$

Con cui si può costruire una normale con media e varianza scelti:

$$X = \mu + \sigma Z_{(1 \text{ oppure } 2)} \Rightarrow X \sim N(\mu, \sigma^2)$$

- **Metodo di accettazione-rifiuto**

Data $f(x)$, si sceglie $g(x)$ tale che $\forall x \ f(x) \leq M g(x)$ ($M \geq \sup_x \frac{f(x)}{g(x)}$);

Si generano $x \sim g(x)$ e $u \sim U(0, 1)$;

Si accetta il valore se $u \leq \frac{f(x)}{M g(x)}$.

Definizione Una statistica è una funzione del campione $(X_1, \dots, X_n)$:

$$T : \mathbb{R}^n \rightarrow \mathbb{R}$$

Dato che il campione è formato da v.a. la statistica in sé è una v.a.

Alcune statistiche sono:

- **Media campionaria**

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

- **Varianza campionaria**

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

- **Statistiche d'ordine**

Ottenute ordinando il campione in ordine crescente:

$$X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$$

dove $X_{(i)}$ rappresenta la i -esima osservazione più piccola del campione.

- **Mediana campionaria**

$$M = \begin{cases} X_{(\frac{n+1}{2})} & \text{se } n \text{ è dispari,} \\ \frac{X_{(\frac{n}{2})} + X_{(\frac{n}{2}+1)}}{2} & \text{altrimenti.} \end{cases}$$

- **Minimo e Massimo**

$$X_{(1)}, X_{(n)}$$

Alcune proprietà che può avere una statistica:

Sufficienza La statistica contiene tutta l'informazione presente nel campione riguardo a θ .

Minimalità La statistica è funzione di qualsiasi altra statistica sufficiente.

Completezza Non esistono funzioni non banali della statistica che hanno valore atteso 0 per ogni valore assumibile da θ .

Ancillarità La distribuzione della statistica non dipende dal parametro da stimare.

Teorema 1 (Basu). *Qualsiasi statistica sufficiente e limitatamente completa¹ è indipendente da qualsiasi statistica ancillare.*

Esistono dei metodi per capire se una statistica ha le prime 2 proprietà:

- **Sufficienza**

– Capire se $P_\theta(X = x \mid T(X) = t)$ non dipende da θ ;

¹La completezza limitata è una forma più debole della completezza.

– Usare la fattorizzazione di Neyman-Fisher:

$$\prod_{i=1}^n f_{\theta}(x_i) = g(T(x), \theta) h(x)$$

Ossia capire se si può “dividere” la produttoria in una parte che dipende dal parametro e dalla statistica e un'altra che dipende solo dal campione.

- **Minimalità**

Verificare che (dati 2 campioni x, y): $\frac{\prod_{i=1}^n f_{\theta}(x_i)}{\prod_{i=1}^n f_{\theta}(y_i)}$ non dipende da $\theta \iff T(X) = T(Y)$

Esempi:

- **Esponenziale con λ ignota**

$$\lambda e^{-\lambda x} \rightarrow \prod_{i=1}^n \lambda e^{-\lambda x_i} \rightarrow \mathbf{1} * \lambda^n e^{-\lambda \sum_{i=1}^n x_i}$$

In questo caso l'intera formula è $g(T(X), \lambda)$, moltiplicando la formula per 1 posso prendere quest'ultimo come $h(x)$. Quindi la somma è sufficiente.

- **Uniforme $(0, \theta)$**

(Qui devo considerare anche il vincolo dato che in questo compare θ)

$$\frac{1}{\theta}, 0 < x < \theta \rightarrow \prod_{i=1}^n \frac{1}{\theta} \mathbf{1}_{(0 < x_i < \theta)} \rightarrow \frac{1}{\theta^n} \mathbf{1}_{(x_{(n)} < \theta)}$$

(Il prodotto delle funzioni indicatrici vale 1 solamente se ogni x_i è minore di θ , in modo equivalente vale 1 solo se θ è maggiore dell'elemento massimo del campione)

Mettendo a rapporto:

$$\frac{\frac{1}{\theta^n} \mathbf{1}_{(x_{(n)} < \theta)}}{\frac{1}{\theta^n} \mathbf{1}_{(y_{(n)} < \theta)}} = \frac{\mathbf{1}_{(x_{(n)} < \theta)}}{\mathbf{1}_{(y_{(n)} < \theta)}}$$

Qui l'unico caso in cui non compare θ è se la frazione equivale ad 1, cosa che succede solo se il massimo dei due campioni è lo stesso valore. Quindi $x_{(n)}$ è sufficiente minimale.

3 Stimatori

Definizione Uno stimatore (puntuale) è una statistica che, a partire dai valori del campione, fornisce una stima di un parametro ignoto.

3.1 MLE

Lo stimatore di massima verosimiglianza si ottiene con la seguente formula:

$$\hat{\theta}_{MLE} = \arg \max_{\theta \in \Theta} \prod_{i=1}^n f_{\theta}(x_i)$$

Spesso conviene lavorare con la versione logaritmica:

$$\arg \max_{\theta \in \Theta} \sum_{i=1}^n \log f_{\theta}(x_i)$$

Un metodo comune per trovare il massimo è usare le derivate:

$$\frac{x^{\frac{1-\theta}{\theta}}}{\theta} \rightarrow \theta^{-n} \left(\prod_{i=1}^n x_i \right)^{\frac{1-\theta}{\theta}} \xrightarrow{\log} -n \log \theta + \theta^{-1} \sum \log x_i - \sum \log x_i$$

$$\begin{aligned} \frac{dl}{d\theta} &\rightarrow -\frac{n}{\theta} - \frac{\sum \log x_i}{\theta^2} \stackrel{=0}{\rightarrow} \hat{\theta} = -\frac{\sum \log x_i}{n} \\ \frac{d^2l}{d\theta^2} &\rightarrow \frac{n}{\theta^2} + \frac{2 \sum \log x_i}{\theta^3} \\ &= \frac{n}{\theta^2} + \frac{2(-n\theta)}{\theta^3} \quad (\text{nel punto critico } \sum \log x_i = -n\theta) \\ &= \frac{n}{\theta^2} \left(1 + \frac{2(-n\theta)}{n\theta} \right) = -\frac{n}{\theta^2} < 0 \end{aligned}$$

Quindi il punto critico è un massimo e di conseguenza MLE.

N.B.² Per n grande e sotto opportune condizioni di regolarità:

$$\hat{\theta}_{MLE} \stackrel{a}{\sim} N\left(\theta_{\text{vero}}, \frac{1}{nI(\theta)}\right)$$

⁵La definizione di $I(\theta)$ è nella sezione 3.4.

3.2 Metodo dei momenti

Dati k parametri ignoti, gli stimatori dei momenti si ottengono uguagliando i momenti teorici⁶ della distribuzione con i relativi momenti campionari:

$$\begin{aligned} E[X] &= m_1 \\ E[X^2] &= m_2 \\ &\vdots \\ E[X^k] &= m_k \end{aligned}$$

$$\text{Dove } m_r = \frac{1}{n} \sum_{i=1}^n X_i^r, \quad r = 1, \dots, k.$$

Per esempio una normale con entrambi i parametri ignoti:

$$\begin{aligned} E[X] &= \mu, & E[X^2] &= \mu^2 + \sigma^2 \\ \bar{X} &= \frac{1}{n} \sum_{i=1}^n X_i, & \bar{X}^2 &= \frac{1}{n} \sum_{i=1}^n X_i^2 \end{aligned}$$

$$\begin{aligned} E[X] = m_1 &\longrightarrow \hat{\mu}_{MM} = \bar{X}, \\ E[X^2] = m_2 &\longrightarrow \mu^2 + \sigma^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 \\ &\longrightarrow \hat{\sigma}_{MM}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 \text{ (Uso } \hat{\mu}_{MM}) \end{aligned}$$

N.B. Il metodo dei momenti può presentare problemi:

- Per la distribuzione di Cauchy il primo momento non esiste, quindi questo metodo non è applicabile;
- Per

$$\frac{1 + \theta \cos x}{2\pi}$$

si ha $E[X] = \pi$ (non compare θ), bisogna quindi utilizzare un momento di ordine superiore.

⁶I momenti teorici sono riferiti alla singola variabile aleatoria X , non al campione.

3.3 Bayes

Definizione La distribuzione a priori ($\pi(\theta)$) è una distribuzione di probabilità assegnata al parametro prima di osservare i dati⁷.

Definizione La verosimiglianza è la probabilità (o densità) del campione osservato vista come funzione del parametro:

$$L(\theta; x) = \prod_{i=1}^n f_{\theta}(x_i).$$

Definizione La distribuzione a posteriori (posterior) è la distribuzione del parametro dopo aver osservato il campione, è data da:

$$\pi(\theta | x) \propto L(\theta; x)\pi(\theta)$$

Per ottenere lo stimatore bayesiano si sceglie una funzione di perdita⁸:

- $(\theta - a)^2$ (MSE):
Lo stimatore è la media della distribuzione a posteriori;
- $|\theta - \hat{\theta}|$:
Lo stimatore è la mediana della distribuzione a posteriori;
- $\arg \max_{\theta} \pi(\theta | x)$ ⁹:
Lo stimatore è il valore che massimizza la posterior;

Esempio:

$$f(x | \theta) = \theta^x (1 - \theta)^{1-x}, \quad 0 < \theta < 1, \quad \pi(\theta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1}$$

$$L(\theta; x) = \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{\sum_{i=1}^n (1-x_i)} = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i}$$

$$\pi(\theta | x) \propto \theta^{\sum x_i} (1 - \theta)^{n - \sum x_i} \theta^{\alpha-1} (1 - \theta)^{\beta-1} \propto \theta^{\alpha + \sum x_i - 1} (1 - \theta)^{\beta + n - \sum x_i - 1}$$

$$\text{Che è una Beta} \left(\alpha + \sum_{i=1}^n x_i, \beta + n - \sum_{i=1}^n x_i \right), \text{ scegliendo } MSE \rightarrow \hat{\theta}_B = \frac{\alpha + \sum_{i=1}^n x_i}{\alpha + \beta + n}$$

⁷Quando una distribuzione viene utilizzata come prior, la variabile generica della densità (comunemente x) viene indicata con il simbolo del parametro stesso.

⁸Qui θ rappresenta il vero valore del parametro, a la stima.

⁹Per parametri discreti.

3.4 Proprietà e teoremi vari

Definizione L'informazione di Fisher¹⁰ è definita come:

$$I(\theta) = E_{\theta} \left[\left(\frac{\partial}{\partial \theta} \log f_{\theta}(x) \right)^2 \right]$$

Oppure¹¹:

$$-E_{\theta} \left[\frac{\partial^2}{\partial \theta^2} \log f_{\theta}(x) \right]$$

Definizione Lo squarto quadratico medio è definito come:

$$MSE(\hat{\theta}) = Var_{\theta}(\hat{\theta}) + (E_{\theta}[\hat{\theta}] - \theta)^2$$

Definizione La disuguaglianza di Cramér–Rao è definita come:

$$Var(\hat{\theta}) \geq \frac{\left(\frac{d}{d\theta} E[\hat{\theta}] \right)^2}{nI(\theta)}$$

Alcune proprietà che può avere uno stimatore:

- **Correttezza**¹²

$$E[\hat{\theta}] = \theta$$

(Per uno stimatore corretto il secondo termine di MSE non compare e la parte dx di Cramér–Rao diventa $1/nI(\theta)$)

- **Consistenza**

$$\hat{\theta} \xrightarrow{P} \theta \text{ quando } n \rightarrow \infty$$

- **Efficienza**

Raggiunge il limite inferiore di Cramér–Rao ed è corretto.

¹⁰Si riferisce alla singola variabile aleatoria X , per avere quella del campione basta moltiplicare per la taglia dello stesso.

¹¹Sotto opportune condizioni di regolarità e se la funzione è doppiamente differenziabile.

¹²Uno stimatore corretto viene anche chiamato non distorto.

Definizione Uno stimatore è detto **UMVU** se non è distorto ed ha varianza minima tra tutti gli stimatori non distorti, per ogni valore del parametro.

N.B. Stimatore efficiente $\Rightarrow$ Stimatore UMVU

Teorema 2 (Lehmann–Scheffé). *Se uno stimatore non è distorto ed è funzione di una statistica sufficiente e completa, allora è lo stimatore UMVU del parametro.*

Teorema 3 (Rao–Blackwell). *Dato uno stimatore $\hat{\theta}$ ed una statistica sufficiente T :*

$$\hat{\theta}_{RB} = E[\hat{\theta} \mid T]$$

è uno stimatore per cui:

$$\text{Var}(\hat{\theta}_{RB}) \leq \text{Var}(\hat{\theta}), \quad E[\hat{\theta}_{RB}] = E[\hat{\theta}]$$

Per il teorema di Lehmann–Scheffé si ha inoltre che se $\hat{\theta}$ è corretto e T è anche completa $\hat{\theta}_{RB}$ è UMVU.

Dimostrazione.

Per la legge delle aspettative iterate:

$$E[\hat{\theta}_{RB}] = E[E[\hat{\theta} \mid T]] = E[\hat{\theta}]$$

Per la legge della varianza totale:

$$\text{Var}(\hat{\theta}) = E[\text{Var}(\hat{\theta} \mid T)] + \text{Var}(E[\hat{\theta} \mid T]) = E[\text{Var}(\hat{\theta} \mid T)] + \text{Var}(\hat{\theta}_{RB})$$

Dove **il primo termine** è maggiore o uguale a 0, quindi **il secondo** è minore o uguale alla **varianza di $\hat{\theta}$** . □

4 Test d'ipotesi e intervalli di confidenza

4.1 IC

Definizione Una quantità pivotale ($Q(X, \theta)$) è una funzione del campione e del parametro la cui distribuzione non dipende dal valore del parametro.

Definizione Un intervallo di confidenza per un parametro è un intervallo costruito partendo dal campione, tale che:

$$P(u(X) < \theta < v(X)) = \gamma$$

Dove γ è detto livello di confidenza. Con un livello di confidenza del 95%, se si ripete molte volte il campionamento e per ogni campione si costruisce un intervallo con la stessa procedura, circa il 95% degli intervalli ottenuti conterrà il vero valore del parametro.

Definizione Il livello di significatività è definito come $\alpha = 1 - \gamma$.

Un metodo comune per costruire questi intervalli consiste nello sfruttare le quantità pivotali, ad esempio per una normale:

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1), \quad \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}, \quad \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$$

Si possono usare rispettivamente per costruire gli intervalli di:

- **Media (varianza nota):**

$$\begin{aligned} \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1) &\implies P\left(-z_{1-\frac{\alpha}{2}} \leq \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq z_{1-\frac{\alpha}{2}}\right) = 1 - \alpha \\ &\implies \mu \in \left(\bar{X} - z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}\right) \end{aligned}$$

- **Media (varianza ignota):**

$$\begin{aligned} \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1} &\implies P\left(-t_{1-\frac{\alpha}{2}, n-1} \leq \frac{\bar{X} - \mu}{S/\sqrt{n}} \leq t_{1-\frac{\alpha}{2}, n-1}\right) = 1 - \alpha \\ &\implies \mu \in \left(\bar{X} - t_{1-\frac{\alpha}{2}, n-1} \frac{S}{\sqrt{n}}, \bar{X} + t_{1-\frac{\alpha}{2}, n-1} \frac{S}{\sqrt{n}}\right) \end{aligned}$$

- **Varianza:**

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2 \quad \Rightarrow \quad P\left(\chi_{\frac{\alpha}{2}, n-1}^2 \leq \frac{(n-1)S^2}{\sigma^2} \leq \chi_{1-\frac{\alpha}{2}, n-1}^2\right) = 1-\alpha$$

$$\Rightarrow \quad \sigma^2 \in \left(\frac{(n-1)S^2}{\chi_{1-\frac{\alpha}{2}, n-1}^2}, \frac{(n-1)S^2}{\chi_{\frac{\alpha}{2}, n-1}^2}\right)$$

Esempi:

- **Media:**

$$\bar{X} = 12, \quad n = 100, \quad S = 4, \quad \alpha = 0.05, \quad \sigma = 4$$

- **Varianza nota:**

$$z_{1-\frac{\alpha}{2}} = z_{0.975} = 1.96 \rightarrow 12 \pm 1.96 \frac{4}{\sqrt{100}} = 12 \pm 0.784$$

$$IC_{95\%} = (11.216, 12.784)$$

- **Varianza ignota:**

Ipotizziamo $S = 4$

$$t_{1-\frac{\alpha}{2}, n-1} = t_{0.975, 99} \approx 1.984 \rightarrow 12 \pm 1.984 \frac{4}{\sqrt{100}} = 12 \pm 0.794$$

$$IC_{95\%} = (11.206, 12.794)$$

- **Varianza:**

$$S^2 = 9, \quad n = 20, \quad \alpha = 0.05$$

$$\chi_{0.975, 19}^2 = 32.852, \quad \chi_{0.025, 19}^2 = 8.907 \rightarrow \left(\frac{19 \cdot 9}{32.852}, \frac{19 \cdot 9}{8.907}\right)$$

$$IC_{95\%} = (5.20, 19.20)$$

4.2 Test

Definizione Un test d'ipotesi è una procedura che permette di decidere, basandosi sul campione, se rifiutare una certa ipotesi sul parametro. Si hanno 2 ipotesi:

- H_0 (ipotesi nulla, si considera vera fino a prova contraria)
- H_1 (ipotesi alternativa)

$$\Theta = \Theta_0 \cup \Theta_1, \quad \Theta_0 = \{\theta \in \Theta \mid H_0 \text{ è vera}\}, \quad \Theta_1 = \{\theta \in \Theta \mid H_1 \text{ è vera}\}$$

Definizione La regione critica (C) è l'insieme di valori della statistica di test per cui H_0 viene rifiutata.

Definizione La funzione di potenza è la probabilità di rifiutare H_0 al variare del parametro.

$$P_\theta(T(X) \in C)$$

Definizione L'errore di I specie consiste nel rifiutare H_0 quando essa è vera¹³:

$$\sup_{\theta \in \Theta_0} P_\theta(T(X) \in C) \leq \alpha$$

Definizione L'errore di II specie consiste nel non rifiutare H_0 quando essa è falsa:

$$\beta = P_\theta(T(X) \notin C) \quad \theta \in \Theta_1.$$

Definizione La potenza del test è $1 - \beta$.

$\alpha \downarrow \Rightarrow \beta \uparrow \Rightarrow \text{Potenza test} \downarrow$

Definizione Un test di livello α è **MP** se, tra tutti i test dello stesso livello, ha la funzione di potenza massima per un valore fissato $\theta_1 \in \Theta_1$.

Definizione Un test di livello α è **UMP** se, tra tutti i test dello stesso livello, ha la funzione di potenza massima per ogni $\theta \in \Theta_1$.

¹³ α è il livello di significatività.

Tipi di test:

- **Test bilaterale:**

$$H_0 : \theta = \theta_0, \quad H_1 : \theta \neq \theta_0$$

La regione critica è divisa in due code della distribuzione.

- **Test unilaterale destro:**

$$H_0 : \theta \leq \theta_0, \quad H_1 : \theta > \theta_0$$

La regione critica si trova nella coda destra della distribuzione.

- **Test unilaterale sinistro:**

$$H_0 : \theta \geq \theta_0, \quad H_1 : \theta < \theta_0$$

La regione critica si trova nella coda sinistra della distribuzione.

Lemma 1 (Neyman-Pearson). *Per due ipotesi semplici $H_0 : \theta = \theta_0$, $H_1 : \theta = \theta_1$ il test che rifiuta (H_0) quando:*

$$\Lambda(X) = \frac{L(\theta_0; X)}{L(\theta_1; X)} \leq k \quad \text{dove } k \text{ è tale che } P_{\theta_0}(\Lambda(X) \leq k) = \alpha$$

è MP.

Esempi:

- Un'azienda dichiara che il peso medio delle confezioni è di 500 g, si sospetta però che il peso medio sia maggiore.

Da un campione di $n = 36$ confezioni si ottiene $\bar{X} = 504$, $\sigma = 12$. Si vuole un test con $\alpha = 0.05$

$$H_0 : \mu \leq 500, \quad H_1 : \mu > 500.$$

Essendo la varianza nota, si può usare:

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} = \frac{504 - 500}{12/\sqrt{36}} = \frac{4}{2} = 2$$

$$C = \{Z > z_{1-\alpha}\} = \{Z > 1.645\} = \{2 > 1.645\} \rightarrow \text{Rifiuto } H_0$$

- Si vuole verificare se il tempo medio di consegna di un servizio sia diverso da 30 minuti.

Da un campione di $n = 16$ osservazioni si ottiene $\bar{X} = 32$, $S = 5$. Si vuole un test con $\alpha = 0.05$

$$H_0 : \mu = 30, \quad H_1 : \mu \neq 30.$$

La varianza è ignota, quindi si usa:

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} = \frac{32 - 30}{5/\sqrt{16}} = \frac{2}{1.25} = 1.6$$

$$C = \{|T| > t_{15, 1-\alpha/2}\} = \{|T| > 2.131\} = \{|1.6| > 2.131\} \rightarrow \text{Non rifiuto } H_0$$

- Si presume una deviazione standard $\sigma_0 = 4$.

Da un campione normale di dimensione $n = 20$ si ottiene $S^2 = 25$. Si vuole un test con $\alpha = 0.05$

$$H_0 : \sigma^2 = 16, \quad H_1 : \sigma^2 \neq 16.$$

$$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2} = \frac{19 \cdot 25}{16} = 29.69$$

$$C = \{\chi^2 < \chi_{19, 0.025}^2\} \cup \{\chi^2 > \chi_{19, 0.975}^2\} = \{\chi^2 < 8.907\} \cup \{\chi^2 > 32.852\} \rightarrow \text{Non rifiuto } H_0$$

- Ho $(1-\theta)^{x-1}\theta$, dato un campione di taglia 1 ($x = 4$) e una significatività del 5%:

$$H_0 : \theta < 1\% ?$$

Questa è una distribuzione geometrica, più cresce θ meno prove dovrò fare per avere un successo. Quindi $C = \{x \leq c\}$.

$$\begin{aligned} \sup_{\theta \leq 0.01} P_\theta(X \leq c) &= P_{0.01}(X \leq c) \leq 0.05 & (P_p(X \geq c+1) = (1-p)^c) \\ &= 1 - (1 - 0.01)^c \leq 0.05 \rightarrow 1 - 0.99^c \leq 0.05 \\ &\rightarrow 0.99^c \geq 0.95 \rightarrow c \leq \frac{\ln 0.95}{\ln 0.99} \rightarrow c \leq 5.12 \rightarrow c = 5 \end{aligned}$$

Quindi $C = \{x \leq 5\}$, rifiuto H_0 .

- Una moneta viene lanciata 10 volte. Si vuole verificare se la moneta è equa. (Significatività del 5%)

$$H_0 : p = 0.5, \quad H_1 : p = 0.8.$$

Uso il lemma di Neyman-Pearson.

$$\begin{aligned} & \frac{\binom{10}{x}(0.5)^x(0.5)^{10-x}}{\binom{10}{x}(0.8)^x(0.2)^{10-x}} = \\ & = \frac{(0.5)^{10}}{(0.8)^x(0.2)^{10-x}} = \\ & = \left(\frac{0.5}{0.8}\right)^x \left(\frac{0.5}{0.2}\right)^{10-x} = \\ & = (0.625)^x (2.5)^{10-x}. \end{aligned}$$

$$P_{0.5}(X \geq k) \leq 0.05 \quad (\text{Il rapporto decresce rispetto ad } x)$$

$$\begin{aligned} P_{0.5}(X \geq 9) &= P(X = 9) + P(X = 10) \\ &= \binom{10}{9}(0.5)^{10} + \binom{10}{10}(0.5)^{10} \\ &= \frac{10 + 1}{1024} = 0.0107 < 0.05 \end{aligned}$$

$$P_{0.5}(X \geq 8) = \frac{45 + 10 + 1}{1024} = 0.0547 > 0.05.$$

Quindi $C = \{X \geq 9\}$.

Si noti come esiste una correlazione con gli intervalli di confidenza. Nel terzo esempio, costruendo un intervallo di confidenza con livello $1 - \alpha = 95\%$, si ottiene

$$(14.46, 52.78)$$

che contiene il valore 16, ossia il valore ipotizzato sotto H_0 . Questo non è un caso: gli intervalli di confidenza contengono esattamente i valori del parametro per i quali il corrispondente test d'ipotesi non rifiuta H_0 .

Definizione Il p-value è un valore che misura quanto i dati osservati siano compatibili con l'ipotesi nulla: un valore piccolo indica che il risultato osservato è poco plausibile se H_0 fosse vera.

5 Test χ^2

5.1 Bontà di adattamento

Definizione Una variabile categorica è una variabile che assume valori rappresentati da categorie, utilizzate per classificare le osservazioni in gruppi distinti.

Data una variabile con k categorie e un campione di dimensione n , si vuole testare:

$$H_0 : (O_1, \dots, O_k) \sim \text{Mult}(n, p_1, \dots, p_k) \text{ (con } O_i \text{ osservazioni della categoria } i)$$

La statistica usata è:

$$\sum_{i=1}^k \frac{(O_i - E[X_i])^2}{E[X_i]} \stackrel{a}{\sim} \chi_{k-m-1}^2 \text{ (} m \text{ è il numero di parametri da stimare e } E[X_i] = np_i)$$

La convergenza vale sotto H_0 , per n grande e se $\forall i \ E[X_i] \geq 5$.

$$\text{La regione critica è: } \{ \text{Valore statistica} > \chi_{1-\alpha, k-m-1}^2 \}$$

Esempio (5%):

$$\begin{array}{c|c|c} O_1 & O_2 & O_3 \\ \hline 10 & 68 & 112 \end{array}$$

Con $(p_1 = (1 - \theta)^2, \ p_2 = 2\theta(1 - \theta), \ p_3 = \theta^2)$:

$$L = \frac{190!}{10! 68! 112!} ((1 - \theta)^2)^{10} (2\theta(1 - \theta))^{68} (\theta^2)^{112}$$

$$\frac{dl}{d\theta} = 0 \quad \longrightarrow \quad \hat{\theta} = \frac{68 + 2(112)}{2 \cdot 190} = 0.768$$

$$E_1 = 190(1 - 0.768)^2 \approx 10.18,$$

$$E_2 = 190(2 \cdot 0.768(1 - 0.768)) \approx 67.68,$$

$$E_3 = 190(0.768)^2 \approx 112.14$$

$$\frac{(10 - 10.18)^2}{10.18} + \frac{(68 - 67.68)^2}{67.68} + \frac{(112 - 112.14)^2}{112.14} \approx 0.005$$

$$\chi_{0.95,1}^2 = 3.84 > 0.005 \rightarrow \text{Non rifiuto } H_0$$

5.2 Indipendenza

Definizione Una tabella di contingenza è una tabella a doppia entrata che riporta le frequenze congiunte di due (o più) variabili categoriche, mostrando quante osservazioni appartengono a ciascuna combinazione di categorie.

Date due variabili categoriche, inserite in una tabella con r righe e c colonne. Si vuole testare:

$$H_0 : \text{le due variabili sono indipendenti}$$

La statistica del test è:

$$X^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}} \stackrel{a}{\sim} \chi_{(r-1)(c-1)}^2$$

$$\left(\text{con } O_{ij} \text{ frequenza osservata nella cella } (i, j) \text{ e } E_{ij} = \frac{(\text{totale riga } i)(\text{totale colonna } j)}{n} \right)$$

Valgono gli stessi criteri del test precedente per la convergenza.

$$\text{La regione critica è: } \left\{ \text{Valore statistica} > \chi_{1-\alpha, (r-1)(c-1)}^2 \right\}$$

Esempio (10%):

$A \backslash B$	B_1	B_2	B_3	Tot.
A_1	15	23	10	48
A_2	25	19	8	52
Tot.	40	42	18	100

$$\begin{aligned} E_{11} &= \frac{48 \cdot 40}{100} = 19.2, & E_{12} &= \frac{48 \cdot 42}{100} = 20.16, & E_{13} &= \frac{48 \cdot 18}{100} = 8.64, \\ E_{21} &= \frac{52 \cdot 40}{100} = 20.8, & E_{22} &= \frac{52 \cdot 42}{100} = 21.84, & E_{23} &= \frac{52 \cdot 18}{100} = 9.36. \end{aligned}$$

$$\frac{(15 - 19.2)^2}{19.2} + \frac{(23 - 20.16)^2}{20.16} + \frac{(10 - 8.64)^2}{8.64} + \frac{(25 - 20.8)^2}{20.8} + \frac{(19 - 21.84)^2}{21.84} + \frac{(8 - 9.36)^2}{9.36} \approx 2.66$$

$$\chi_{0.90, 2}^2 = 4.61 > 2.66 \rightarrow \text{Non rifiuto } H_0$$

6 ANOVA a una via

Assumendo:

- campioni indipendenti;
- normalità delle popolazioni;
- omoschedasticità (uguaglianza delle varianze);

Si vuole testare:

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_k$$

La statistica del test è:

$$\frac{\frac{\sum_{i=1}^k n_i (\bar{X}_i - \bar{X})^2}{k-1}}{\frac{\sum_{i=1}^k \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_i)^2}{n-k}} \stackrel{H_0}{\sim} F_{k-1, n-k}$$

(con n_i = numerosità del gruppo i , $\bar{X}_i$ media del gruppo i , $\bar{X}$ media generale)

La regione critica è: {Valore statistica $> F_{1-\alpha, k-1, n-k}$ }

Esempio (5%):

	G_1	G_2	G_3	G_4
1	279	378	172	381
2	338	275	335	346
3	334	412	335	340
4	198	265	282	471
5	303	286	250	318

$$\bar{X}_1 = \frac{279 + 338 + 334 + 198 + 303}{5} = 290.4$$

$$\bar{X}_2 = \frac{378 + 275 + 412 + 265 + 286}{5} = 323.2$$

$$\bar{X}_3 = \frac{172 + 335 + 335 + 282 + 250}{5} = 274.8$$

$$\bar{X}_4 = \frac{381 + 346 + 340 + 471 + 318}{5} = 371.2$$

$$\bar{X} = \frac{1}{20} \sum_{i=1}^4 \sum_{j=1}^5 X_{ij} = 314.9$$

$$\begin{aligned}
SS_B &= \sum_{i=1}^4 n_i (\bar{X}_i - \bar{X})^2 = 5[(290.4 - 314.9)^2 + (323.2 - 314.9)^2 \\
&\quad + (274.8 - 314.9)^2 + (371.2 - 314.9)^2] \approx 27234.20 \\
SS_W &= \sum_{i=1}^4 \sum_{j=1}^5 (X_{ij} - \bar{X}_i)^2 \approx 63953.60
\end{aligned}$$

$$\frac{MS_B}{MS_W} = \frac{SS_B/3}{SS_W/16} = \frac{9078.07}{3997.10} \approx 2.27$$

$$F_{0.95,3,16} \approx 3.24 > 2.27 \rightarrow \text{Non rifiuto } H_0$$

7 Algoritmo EM

Definizione L'algoritmo EM (Expectation-Maximization) è un metodo utilizzato per stimare i parametri di un modello quando sono presenti dati incompleti o variabili latenti.

Si vuole massimizzare la verosimiglianza dei dati osservati, ma la variabile latente rende difficile massimizzare direttamente, si considera quindi la verosimiglianza completa:

$$L_c(\theta|X, Z) = p(X, Z|\theta) \quad (X \text{ dati osservati, } Z \text{ dati latenti, } \theta \text{ parametri})$$

L'algoritmo procede alternando due passi:

$$\boxed{\text{E-step} \quad Q(\theta|\theta^{(t)}) = E_{Z|X, \theta^{(t)}}[\log p(X, Z|\theta)]}$$

$$\boxed{\text{M-step} \quad \theta^{(t+1)} = \arg \max_{\theta} Q(\theta|\theta^{(t)})}$$

Fino a convergere:¹⁴

$$|\theta^{(t+1)} - \theta^{(t)}| < \varepsilon.$$

È garantito che ad ogni iterazione la verosimiglianza osservata non diminuisca:

$$L(\theta^{(t+1)}|X) \geq L(\theta^{(t)}|X).$$

¹⁴La convergenza può essere verso un massimo locale, quindi la soluzione dipende dalla scelta iniziale $\theta^{(0)}$.